使用说明

自动化 ML 模型评估平台。通过一个 JSON 请求完成：模型下载 → Triton 配置生成 → 热加载 → Ray Serve 推理部署。

快速启动

```
source env.sh
bash run.sh
```

启动后系统自动完成：启动 Triton（explicit 模式） → 启动 Ray Serve → 部署默认 pipeline。

使用方式

所有接口端口 **2866**。

1. 部署 Pipeline

发送 POST 请求指定模型，系统自动完成下载、配置、加载、部署：

```
curl -s -X POST http://localhost:2866/config \
  -H "Content-Type: application/json" \
  -d '{
    "models": [
      {"model_type": "Object_Detection", "model_name": "CCTH-Unit",
"timestamp": "20260317083337"},
      {"model_type": "Classification", "model_name": "Suntory-ES-Sku",
"timestamp": "20260318151232"}
    ]
  }' | python3 -m json.tool
```

也可以用脚本：`bash scripts/req_config.sh`

Pipeline 类型根据 `model_type` 组合自动推断：

model_type 组合	Pipeline	推理端点
Object_Detection only	`unit`	`/unit`
Classification only	`sku`	`/sku`
Object_Detection + Classification	`unit_sku`	`/unit`, `/unit_sku`

2. 查看状态

```
# 当前配置
curl -s http://localhost:2866/config | python3 -m json.tool

# Triton + Pipeline 健康状态
curl -s http://localhost:2866/config/status | python3 -m json.tool
```

3. 推理请求

```
# 目标检测
curl -X POST http://localhost:2866/unit \
  -H "Content-Type: application/json" \
  -d '{"image_url": "data/images/unit_test.jpg"}'

# 目标检测 + SKU 分类
curl -X POST http://localhost:2866/unit_sku \
  -H "Content-Type: application/json" \
  -d '{"image_url": "data/images/unit_test.jpg"}'

# 批量推理
curl -X POST http://localhost:2866/unit \
  -H "Content-Type: application/json" \
  -d '{"image_urls": ["data/images/4653849.png",
"data/images/unit_test.jpg"]}'
```

或使用脚本：`bash scripts/req_unit.sh` / `bash scripts/req_unit_sku.sh`

4. 切换模型

直接再发一次 POST /config，旧模型自动卸载，新模型自动加载：

```
curl -s -X POST http://localhost:2866/config \
  -H "Content-Type: application/json" \
  -d '{
    "models": [
      {"model_type": "Object_Detection", "model_name": "NewModel",
"timestamp": "20260320160144"}
    ]
  }' | python3 -m json.tool
```

5. 重启恢复

Pipeline 配置自动持久化到 `config/active_pipeline.json`。重启 Ray Serve 后自动恢复，无需重新 POST。

API 汇总

方法	端点	说明
POST	/config	部署 pipeline（JSON 配置）
GET	/config	查看当前配置
GET	/config/status	查看 Triton + Pipeline 状态
POST	/unit	目标检测推理
POST	/unit_sku	目标检测 + SKU 分类推理
POST	/visual	视觉搜索

环境变量

变量	默认值	说明
AUTO_CONFIG	1	0 = 旧版手动模式
TRITON_HTTP_URL	http://localhost:8000	Triton HTTP 地址
TRITON_GRPC_HOST	localhost	Triton gRPC 主机
TRITON_GRPC_PORT	8001	Triton gRPC 端口
TRITON_MODEL_REPO	trt_models	模型仓库路径